

第二十四章 数据的分析

数据是信息的载体，从数据中获取信息是统计研究的目的。利用统计图表直观描述数据，可以帮助我们大致了解数据的特征或规律。但要准确把握数据的特征，还需要用数值进行刻画。在社会生活中，人们经常用一个或几个数值刻画一组数据的特征。例如，用人均可支配收入刻画一个地区居民的收入水平，用近视率刻画全国青少年群体的近视情况，用老龄化率刻画一个国家或地区人口的老龄化情况等。这里的人均可支配收入、近视率、老龄化率都是对相关数据某种特征的刻画。

在本章中，我们将在用统计图表直观描述数据的基础上，研究用数值刻画数据特征的方法，学习平均数、中位数、众数、离差平方和、方差、四分位数等一些常用的刻画数据特征的统计量，并用它们解决一些实际问题。对于通过简单随机抽样获取的数据，还将根据样本与总体的关系，用样本的特征估计总体的特征。



24.1 数据的集中趋势

在生活、学习中，我们经常会说某班同学身高较高或成绩较好，这往往比较的是身高或成绩数据的“中心”所在位置，统计中把它称为数据的集中趋势，以前学过的平均数就是刻画数据集中趋势的常见统计量. 本节我们将进一步学习平均数，再学习两个刻画数据集中趋势的统计量——中位数和众数.

24.1.1 平均数

问题 1 甲、乙两组同学的跳绳成绩（单位：次/min）如下：

甲组 182 194 143 185 156

乙组 199 148 242 170 141

你认为哪组的跳绳成绩更好？

为了便于比较，需要分别把每组数据汇总到一个数值. 对于问题 1，可以用每组跳绳成绩的平均数进行比较.

甲组跳绳成绩的平均数为

$$\frac{182+194+143+185+156}{5}=172;$$

乙组跳绳成绩的平均数为

$$\frac{199+148+242+170+141}{5}=180.$$

由于乙组的跳绳成绩的平均数大于甲组的，所以乙组的跳绳成绩更好.

一般地，有 n 个数据 $x_1, x_2, \dots, x_n$ ，我们把

$$\frac{x_1+x_2+\dots+x_n}{n}$$

叫作这 n 个数据的**平均数**（average），记作“ $\bar{x}$ ”. 平均数反映了一组数据取值的平均水平，是刻画数据集中趋势最常用的统计量.

是否可以用每组跳绳成绩的总数比较两组跳绳成绩？如果两组人数不同呢？

根据样本数据计算得到的平均数，叫作**样本平均数**；根据总体数据计算得到的平均数，叫作**总体平均数**.

问题 2 一家公司打算招聘一名英文翻译. 对甲、乙两名应试者进行了听、说、读、写的英语水平测试, 他们的各项成绩 (百分制) 如表 24.1-1 所示.

表 24.1-1

应试者	听	说	读	写
甲	85	78	85	73
乙	73	80	82	83

(1) 如果这家公司想招一名综合能力较强的英文翻译, 计算两名应试者的平均成绩. 从他们的成绩看, 应该录取谁?

(2) 如果这家公司想招一名笔译能力较强的英文翻译, 听、说、读、写成绩按照 2 : 1 : 3 : 4 的比确定, 计算两名应试者的平均成绩. 从他们的成绩看, 应该录取谁?

对于问题 (1), 根据平均数公式, 甲的平均成绩为

$$\frac{85+78+85+73}{4}=80.25,$$

乙的平均成绩为

$$\frac{73+80+82+83}{4}=79.5.$$

因为甲的平均成绩比乙的高, 所以应该录取甲.

对于问题 (2), 听、说、读、写成绩按照 2 : 1 : 3 : 4 的比确定, 这说明各项成绩的“重要程度”有所不同, 读、写的成绩比听、说的成绩更加“重要”. 因此, 甲的平均成绩为

$$\frac{85 \times 2 + 78 \times 1 + 85 \times 3 + 73 \times 4}{2+1+3+4}=79.5,$$

乙的平均成绩为

$$\frac{73 \times 2 + 80 \times 1 + 82 \times 3 + 83 \times 4}{2+1+3+4}=80.4.$$

因为乙的平均成绩比甲的高, 所以应该录取乙.

上述问题 (1) 是利用平均数的公式计算平均成绩, 其中每个数据被认为同等重要. 而问题 (2) 是根据实际需要不同的数据赋予与其重要程度相应的权重, 其中的 2, 1, 3, 4 分别称为听、说、读、写四项成绩的**权**, 相应的

平均数 79.5, 80.4 分别称为甲和乙的听、说、读、写四项成绩的**加权平均数** (weighted average).

一般地, 若 n 个数 $x_1, x_2, \dots, x_n$ 的权分别为 $w_1, w_2, \dots, w_n$, 则

$$\bar{x} = \frac{x_1 w_1 + x_2 w_2 + \dots + x_n w_n}{w_1 + w_2 + \dots + w_n}$$

叫作这 n 个数的加权平均数.



权原指秤锤, 用于称物体, 这里有表示数据重要程度的意思.

思考

如果这家公司想招一名口语能力较强的英文翻译, 听、说、读、写成绩按照 3 : 3 : 2 : 2 的比确定, 那么甲、乙两人谁将被录取? 与上述问题中的 (1)(2) 比较, 你能体会到权的作用吗?

例 1 一次演讲比赛中, 评委将从演讲内容、语言表达、形象风度三个方面为选手打分. 各项成绩均按百分制计, 然后再按演讲内容占 50%、语言表达占 40%、形象风度占 10%, 计算选手的综合成绩. 进入决赛的前两名选手的单项成绩如表 24.1-2 所示, 请确定两人的名次.

表 24.1-2

选手	演讲内容	语言表达	形象风度
A	85	95	95
B	95	85	95

分析: 这个问题可以看成求两名选手三项成绩的加权平均数, 50%, 40%, 10% 表示演讲内容、语言表达、形象风度三项成绩在总成绩中的重要程度, 是三项成绩的权.

解: 选手 A 的综合成绩是

$$\frac{85 \times 50\% + 95 \times 40\% + 95 \times 10\%}{50\% + 40\% + 10\%} = 90,$$

选手 B 的综合成绩是

$$\frac{95 \times 50\% + 85 \times 40\% + 95 \times 10\%}{50\% + 40\% + 10\%} = 91.$$

由上可知, 选手 B 获得第一名, 选手 A 获得第二名.

例 1 中两名选手的单项成绩都是两个 95 分与一个 85 分, 为什么他们的综合成绩不同呢? 你能说一说权是如何影响加权平均数大小的吗?

练习

1. 某公司欲招聘一名公关人员. 对甲、乙两位应试者进行了面试和笔试, 他们的成绩 (百分制) 如下表所示.

应试者	面试	笔试
甲	86	90
乙	92	83

- (1) 如果公司认为面试和笔试成绩同等重要, 从他们的成绩看, 谁将被录取?
- (2) 如果公司认为, 作为公关人员面试成绩应该比笔试成绩更重要, 并分别赋予它们 6 和 4 的权, 计算甲、乙两人各自的平均成绩, 谁将被录取?
2. 某中学规定学生的学期体育成绩满分为 100, 其中早锻炼及体育课外活动占 20%, 期中考试成绩占 30%, 期末考试成绩占 50%. 刘伟的三项成绩 (百分制) 依次是 95, 90, 85, 他这学期的体育成绩是多少?

例 2 某天访问 A, B 两个新闻类网站的用户数分别为 3×10^7 和 1×10^7 , 表 24.1-3 是用户在每个网站的停留时间和关于军事话题调查的统计结果.

表 24.1-3

网站	停留时间的平均数/h	对军事话题感兴趣的百分比/%
A	0.5	24
B	0.7	32

这天两个网站所有用户停留时间的平均数和对军事话题感兴趣的百分比分别是多少?

分析: 由于访问两个网站的用户数不同, 两个网站所有用户停留时间的平均数不能是两个网站各自用户平均停留时间的平均数 $\frac{0.5+0.7}{2}$, 还应考虑访问网站用户数的影响. 两个网站所有用户对军事话题感兴趣的百分比的计算也类似.

解：(1) 根据平均数和总数的关系，可以计算出两个网站所有用户停留时间的平均数为

$$\frac{0.5 \times 3 \times 10^7 + 0.7 \times 1 \times 10^7}{3 \times 10^7 + 1 \times 10^7} = 0.5 \times \frac{3}{4} + 0.7 \times \frac{1}{4} = 0.55.$$

(2) 两个网站所有用户对军事话题感兴趣的百分比为

$$\frac{24\% \times 3 \times 10^7 + 32\% \times 1 \times 10^7}{3 \times 10^7 + 1 \times 10^7} = 24\% \times \frac{3}{4} + 32\% \times \frac{1}{4} = 26\%.$$

0.55 是 0.5 和 0.7 分别以 3×10^7 和 1×10^7 为权的加权平均数，或分别以 $\frac{3}{4}$ 和 $\frac{1}{4}$ 为权的加权平均数。

可以发现，计算分组（两组或更多组）数据的平均数或百分数，只需知道两类信息：一是每组数据的平均数或百分数，二是每组数据的个数（频数），或每组数据个数所占的比值（频率）。根据这两类信息，以频数或频率为权，通过计算加权平均数就可以得到结果。

上述计算分组数据的平均数或百分数的方法在实际中有着重要应用。例如，要计算全国的居民人均可支配收入，可先按省份各自计算其人均可支配收入和人数，再利用加权平均数进行计算。这样不仅减少了把各省份所有调查的数据集中在一起的工作，而且分散了计算量。像这样先按数据分组分别计算，再通过一定算法由各组结果计算出最后结果的方法属于分布式计算。在大数据时代，数据规模非常巨大，在应用中往往对计算的时效性又有很高要求，利用分布式计算不仅可以节约整体计算时间，提高计算效率，还可以减少大量数据传输和存储带来的时间、经济成本。

探究

为了解 5 路公共汽车的运营情况，公交部门统计了某天 5 路公共汽车每个运行班次的载客量，得到表 24.1-4。

表 24.1-4

载客量 x /人	班次（频数）	载客量 x /人	班次（频数）
$1 \leq x < 21$	3	$61 \leq x < 81$	22
$21 \leq x < 41$	5	$81 \leq x < 101$	17
$41 \leq x < 61$	20	$101 \leq x < 121$	15

这天 5 路公共汽车平均每班的载客量是多少（结果取整数）？

从表 24.1-4 中, 我们无法知道每个班次确切的载客量. 为了计算 5 路公共汽车平均每班的载客量, 可以用各组的组中值 (这个小组两个端点的数的平均数) 代表各组的实际数据, 把各组的频数看作相应组中值的权, 通过计算加权平均数得到平均每班载客量的近似值.


经计算, 得到各组的组中值分别为 11, 31, 51, 71, 91, 111, 用它们代表各组每个班次的载客量, 各组的班次 (频数) 分别是这些组中值的权. 因此, 这天 5 路公共汽车平均每班的载客量约为

$$\begin{aligned}\bar{x} &= \frac{11 \times 3 + 31 \times 5 + 51 \times 20 + 71 \times 22 + 91 \times 17 + 111 \times 15}{3 + 5 + 20 + 22 + 17 + 15} \\ &\approx 73 \text{ (人)}.\end{aligned}$$

一般的计算器都有统计功能, 利用统计功能可以求平均数. 使用计算器的统计功能求平均数时, 不同品牌计算器的操作步骤有所不同, 操作时需要参阅计算器的使用说明书. 通常先按某一功能键, 使计算器进入统计状态; 然后依次输入数据 $x_1, x_2, \dots, x_n$ 以及它们的权 $w_1, w_2, \dots, w_n$; 最后按求平均数的功能键, 计算器便会求出 $\frac{x_1 w_1 + x_2 w_2 + \dots + x_n w_n}{w_1 + w_2 + \dots + w_n}$ 的值.

练习

1. 某跳水队为了解运动员的年龄情况, 作了一次年龄调查, 结果如图所示. 求这个跳水队运动员的平均年龄 (结果取整数).



(第 1 题)

2. 某超市有 5 家分店, 其中一天的营业情况统计结果如下表所示.

分店	结账人次	每人每次平均消费金额/元	非现金结账百分比/%
A	4 000	46	70
B	2 000	32	76
C	3 000	68	73
D	7 000	95	85
E	4 000	80	82

这家超市的每人每次平均消费金额和非现金结账百分比分别是多少?

3. 对一个班级学生上学路上所需的时间进行了调查, 统计结果如下表所示.

所需时间 x/min	人数	百分比/%
$1 \leq x < 11$	18	36
$11 \leq x < 21$		46
$21 \leq x < 31$	7	
$31 \leq x < 41$	2	4

- (1) 将统计表补充完整;
(2) 这个班级学生上学路上平均所需时间为多少 (结果取整数)?

对于通过简单随机抽样获取的数据, 可以用样本的平均数估计总体的平均数.

例 3 从校医务室的体检数据中, 随机抽查了 20 名八年级学生, 他们的身高 (单位: cm) 如下:

162 152 166 185 167 175 169 163 168 184
177 162 157 154 171 169 171 169 175 164

估计这所学校八年级学生的平均身高.

分析: 随机抽出的 20 名八年级学生组成一个样本. 可以利用样本的平均身高估计这所学校八年级学生的平均身高.

解: 20 名学生的身高的平均数为

$$\begin{aligned}\bar{x} &= \frac{162+152+\cdots+164}{20} \\ &= 168.\end{aligned}$$

可以估计这所学校八年级学生的平均身高大约为 168 cm.

思考

这所学校八年级学生的平均身高是否一定为 168 cm? 你认为怎样可以提高估计的精确性?

例 4 为测量一批节能灯的使用寿命, 从中随机抽查了 50 盏节能灯, 它们的使用寿命如表 24.1-5 所示.

表 24.1-5

使用寿命 x/h	灯泡数/盏
$7\ 000 \leq x < 8\ 000$	4
$8\ 000 \leq x < 9\ 000$	9
$9\ 000 \leq x < 10\ 000$	12
$10\ 000 \leq x < 11\ 000$	18
$11\ 000 \leq x < 12\ 000$	7

这批节能灯的平均使用寿命是多少?

分析: 随机抽查的 50 盏节能灯组成一个样本. 可以先通过组中值计算出样本的平均使用寿命, 再利用样本的平均使用寿命估计这批节能灯的平均使用寿命.

用全面调查的方法考察这批节能灯的平均使用寿命合适吗?


解: 根据表 24.1-5, 可以得出各组的组中值, 于是样本使用寿命的平均数为

$$\begin{aligned}\bar{x} &= \frac{7\ 500 \times 4 + 8\ 500 \times 9 + 9\ 500 \times 12 + 10\ 500 \times 18 + 11\ 500 \times 7}{50} \\ &= 9\ 800.\end{aligned}$$


可以估计这批节能灯的平均使用寿命大约是 9 800 h.

练习

- 种菜能手李大叔种植了一批新品种黄瓜. 为了解这种黄瓜的生长情况, 他随机抽查了部分黄瓜藤上结出的黄瓜根数, 得到如图所示的条形图. 估计这批新品种黄瓜平均每株结多少根黄瓜 (结果取整数).



(第 1 题)



(第 2 题)

2. 为了绿化环境, 某街道种植一批槐树, 五年后一些树干的周长情况如图所示. 估计这批槐树树干的平均周长 (结果取整数).
3. 学校为了解学生课外阅读的情况, 随机调查了 50 名学生一星期课外阅读的时间, 用了两个不同的表进行统计.

表 1

课外阅读时间 x/h	人数
$0 \leq x < 2$	2
$2 \leq x < 4$	6
$4 \leq x < 6$	23
$6 \leq x < 8$	11
$8 \leq x < 10$	5
$10 \leq x < 12$	3

表 2

课外阅读时间 x/h	人数
$0 \leq x < 4$	8
$4 \leq x < 8$	34
$8 \leq x < 12$	8

- (1) 根据表 1 和表 2 分别估计这所学校所有学生的平均课外阅读时间.
- (2) 用这两个表估计的结果相同吗? 如果不同, 用哪个表估计更合适? 为什么?

24.1.2 中位数和众数

问题 3 在第 149 页“问题 1”中, 计算得到甲和乙两组跳绳成绩的平均数分别为 172 次/min 和 180 次/min. 张华个人的跳绳成绩为 175 次/min, 她认为自己的成绩在甲组中属于中上水平, 在乙组中属于中下水平. 你认可张华的说法吗?

张华的跳绳成绩要处于一个组的中上 (或中下) 水平, 意味着她的成绩超过 (或低于) 这个组至少一半人数的成绩, 即超过 (或低于) 这个组中成绩排名居中的人的成绩.

按从小到大的顺序分别排列两组跳绳成绩, 甲组为

143 156 182 185 194

处在中间位置的数是 182, 它的左侧和右侧各有 2 个数. 乙组为

141 148 170 199 242

处在中间位置的数是 170, 它的左侧和右侧各有 2 个数.

张华的个人跳绳成绩 175 小于甲组中间位置的数 182, 而大于乙组中间位

置的数 170，因此她的成绩在甲组中处于中下水平，在乙组中处于中上水平，这与她自己作出的判断正好相反。

上述中间位置的数 182 和 170，分别是甲组数据和乙组数据集中趋势的一种刻画。一般地，一组数据按从小到大（或从大到小）的顺序排列，处于中间位置的数叫作这组数据的**中位数**（median）。当数据的个数为奇数时，处于中间位置的数就是中位数；当数据的个数为偶数时，居中的数据有两个，取这两个数据的平均数为这组数据的中位数。一组数据按大小排序后，位于中位数左、右两侧的数据个数相同，因此中位数反映了一组数据取值的中间水平。

思考

为什么甲组同学跳绳成绩的平均数比乙组的小，而中位数反而大呢？

例 5 在一次男子马拉松长跑比赛中，随机抽取 12 名选手所用的时间（单位：min）如下：

136 140 129 180 124 154 146 145 158 175 165 148

（1）这组样本数据的中位数是多少？

（2）一名选手所用的时间是 142 min，推测他的成绩是否超过这次比赛中一半以上选手的成绩？

解：（1）先将样本数据按照从小到大的顺序排列：

124 129 136 140 145 146 148 154 158 165 175 180

这组数据的中位数为处于居中两个数据 146，148 的平均数，即中位数为

$$\frac{146+148}{2}=147.$$

因此样本数据的中位数是 147。

（2）根据（1）中得到的样本数据的中位数，可以估计，在这次马拉松比赛中，大约有一半选手的所用时间小于 147 min，有一半选手的所用时间大于 147 min。这名选手的所用时间是 142 min，小于中位数，可以推测他的成绩比一半以上选手的成绩好。

问题 4 班级春游有三个备选地点，经全班一人一票投票，每个地点的得票数如表 24.1-6 所示。

表 24.1-6

地点	北京故宫	颐和园	香山公园
票数	10	26	4

你认为班级的春游地点应该选择哪里？

全班一人一票投票，相当于对全班同学作了一次全面调查，收集到的是每位同学的投票结果（北京故宫、颐和园或香山公园），在统计中这也属于数据. 与前面见到的数据都是数值不同，这里的数据无法进行计算或排序，因此无法通过求它们的平均数或中位数去刻画班级的集体意见. 对于这种情况，一般我们会采取少数服从多数的原则，把得票数最多的地点作为班级的集体意见. 由表 24.1-6 可知，颐和园得票数最多，可以把颐和园作为全班同学意见的代表.

一组数据中出现次数最多的数据叫作这组数据的**众数**（mode）. 例如，在问题 4 中，颐和园就是全班同学意见的众数. 如果一组数据中有两个或两个以上的数据出现的次数并列最多，那么把这几个数据都作为这组数据的众数；如果一组数据中没有出现相同的数据，那么就认为这组数据没有众数. 众数也是刻画数据集中趋势的一种统计量，当一组数据有较多的重复数据时，众数往往能较好地反映其集中趋势.

例 6 一家鞋店在一段时间内销售某种女鞋 30 双，各种尺码鞋的销售量如表 24.1-7 所示.

表 24.1-7

尺码/cm	22	22.5	23	23.5	24	24.5	25
销售量/双	1	2	5	11	7	3	1

你能根据表中的数据为这家鞋店提供进货建议吗？


分析：一般来讲，鞋店比较关心哪种尺码的鞋销售量最大，也就是关心卖出的鞋的尺码组成的一组数据的众数. 一段时间内卖出的 30 双女鞋的尺码组成一个样本数据，通过分析样本数据可以找出样本数据的众数，进而可以估计这家鞋店销售哪种尺码的鞋最多.

分析表 24.1-7 中的数据，你还能鞋店进货提出哪些建议？


解：由表 24.1-7 可以看出，在不同的尺码中，尺码为 23.5 cm 的鞋销售量最大，即众数为 23.5，因此可以建议鞋店多进 23.5 cm 的鞋.

练习

1. 某车间工人每天加工零件数的情况如图所示, 求这些工人每天加工零件数的中位数.



(第 1 题)



(第 2 题)

2. 为研究不同类型软饮料的市场销售情况, 市场调查员在一家超市随机观察并记录了 50 名顾客购买的软饮料类型, 如图所示. 顾客购买的软饮料类型的众数是什么?

虽然平均数、中位数和众数都可以用于刻画一组数据的集中趋势, 但它们刻画的角度并不相同. 在实际应用中, 需要分析具体情况, 选择适当的统计量刻画数据的集中趋势.

例 7 表 24.1-8 是某公司员工月收入的资料.

表 24.1-8

月收入/元	45 000	18 000	10 000	5 000	3 600	3 000
人数	1	1	1	7	6	4

- (1) 分别计算这家公司员工月收入的平均数和中位数.
 (2) 若要反映这家公司员工月收入水平, 你认为用平均数还是中位数? 为什么?

解: (1) 这家公司员工月收入的平均数为

$$\bar{x} = \frac{45\,000 + 18\,000 + 10\,000 + 5\,000 \times 7 + 3\,600 \times 6 + 3\,000 \times 4}{1 + 1 + 1 + 7 + 6 + 4} = 7\,080.$$

将公司 20 名员工的月收入按从小到大排列, 可以得到第 10 个和第 11 个数据分别为 3 600 和 5 000, 可得中位数为

$$\frac{3\,600+5\,000}{2}=4\,300.$$

为什么平均数比中位数高这么多?

(2) 在 20 名员工中, 仅有 3 名员工的月收入在 7 080 元以上, 而另外 17 名员工的月收入都在 7 080 元以下. 因此, 用月收入的平均数代表所有员工的月收入水平不太合适. 而中位数 4 300 说明一半员工的月收入高于 4 300 元, 另一半员工的月收入低于 4 300 元. 相对平均数而言, 中位数更能代表这家公司所有员工的月收入水平.

思考

求出这家公司员工月收入的众数, 用众数刻画这家公司员工月收入水平是否合适? 为什么?

例 8 某商场服装部为了调动营业员的积极性, 决定实行目标管理, 根据目标完成的情况对营业员进行适当的奖励. 为了确定一个适当的月销售目标, 商场服装部统计了每位营业员在某月的销售额 (单位: 万元), 数据如下:

17 18 16 13 24 15 28 26 18 19
22 17 16 19 32 30 16 14 15 26
15 32 23 17 15 15 28 28 16 19

(1) 月销售额在哪个值的人数最多? 中间位置的月销售额是多少? 平均月销售额是多少?

(2) 如果想确定一个较高的销售目标, 你认为在 (1) 的三个销售额中选哪一个作为销售目标合适? 请说明理由.

(3) 如果想让一半左右的营业员都能达到销售目标, 你认为月销售额定为多少合适? 请说明理由.

确定一个适当的月销售目标是一个关键问题. 如果目标定得太高, 多数营业员完不成任务, 会使营业员失去信心; 如果目标定得太低, 不能发挥营业员的潜力.

分析: 商场服装部统计的每位营业员在某月的销售额组成一个样本, 通过分析样本数据的平均数、中位数、众数来估计总体的情况, 从而解决问题.

解: 整理上面的数据得到表 24.1-9 和图 24.1-1.

表 24.1-9

月销售额/万元	13	14	15	16	17	18	19	22	23	24	26	28	30	32
人数	1	1	5	4	3	2	3	1	1	1	2	3	1	2




图 24.1-1

(1) 从表 24.1-9 或图 24.1-1 可以看出, 样本数据的众数是 15, 中位数是 18, 利用计算器求得这组数据的平均数约是 20. 可以推测, 这个服装部营业员的月销售额为 15 万元的人数最多, 中间位置的月销售额是 18 万元, 平均月销售额大约是 20 万元.

用表格整理数据和用图形表示数据, 有助于我们发现数据的特点或规律.

(2) 如果想确定一个较高的销售目标, 这个目标可以定为每月 20 万元 (平均数). 因为从样本数据看, 在平均数、中位数和众数中, 平均数最大. 可以估计, 月销售额定为每月 20 万元是一个较高目标, 大约会有 $\frac{1}{3}$ 的营业员获得奖励.

(3) 如果想让一半左右的营业员能够达到销售目标, 月销售额可以定为每月 18 万元 (中位数). 因为从样本情况看, 月销售额在 18 万元以上 (含 18 万元) 的有 16 人, 占总人数的一半左右. 可以估计, 如果月销售额定为 18 万元, 将有一半左右的营业员获得奖励.

归纳

平均数、中位数和众数都可以刻画一组数据的集中趋势, 但它们各有特点.

平均数是一组数据的平均值, 计算时要用到所有的数据, 它能够充分利用数据提供的信息, 在现实生活中较为常用. 但平均数受极端值 (一组数据中与其余数据差异很大的数据) 的影响较大, 对于存在极端值的数据, 一般平均数的代表性较差.

你知道在体操比赛评分时, 为什么要去掉一个最高分和一个最低分吗?

中位数是一组数据按大小排序后处于中间位置的数, 计算简单, 不易受极端值影响. 但中位数不能充分利用数据提供的信息.

众数是一组数据中出现次数最多的数据，不易受极端值影响。但当各个数据的重复次数差别不大时，众数往往不具有代表性。

练习

1. 王芳在记录第 149 页“问题 1”中乙组同学的跳绳成绩时，把 242 错记成了 224，此时乙组跳绳成绩的平均数和中位数是否都受影响？请你解释其中的原因。

2. 有两组学生的体重数据（单位：kg）：

第 1 组 38 40 44 50 52 52 74

第 2 组 38 40 44 50 52 52 60

(1) 分别求这两组数据的平均数、中位数、众数；

(2) 比较这两组数据的平均数、中位数、众数，结合数据谈一谈它们刻画数据集中趋势的特点。

习题 24.1

复习巩固

1. 某公司有 15 名员工，他们所在部门及相应每人所创年利润如下表所示。

部门	人数	年利润/万元
A	1	100
B	3	80
C	7	50
D	4	30

这个公司平均每人所创年利润是多少？

2. 某校八年级（1）班男生投掷实心球成绩如下表所示。

成绩 x/m	人数	成绩 x/m	人数
$6 \leq x < 7$	2	$9 \leq x < 10$	7
$7 \leq x < 8$	4	$10 \leq x < 11$	3
$8 \leq x < 9$	8	$11 \leq x < 12$	1

这个班男生投掷实心球的平均成绩是多少？

3. 为了检查一批零件的质量，从中随机抽取 10 件，测得它们的长度（单位：mm）如下：

22.36 22.35 22.33 22.35 22.37
22.34 22.38 22.36 22.32 22.35

根据以上数据，估计这批零件的平均长度.

4. 在一次中学生田径运动会上，参加男子跳高的 15 名运动员的成绩如下表所示.

成绩/m	1.45	1.50	1.60	1.65	1.70	1.75
人数	1	4	5	2	2	1

分别求这些运动员成绩的平均数（结果保留小数点后两位）、中位数、众数.

综合运用

5. 在一次青年歌手演唱比赛中，5 位评委给两位歌手的打分分别为

甲 9.5 9.5 9.4 9.6 9.5
乙 9.6 9.6 9.6 9.6 9.0

- (1) 求两位歌手的平均得分.
(2) 如果去掉一个最高分和一个最低分，求两位歌手的平均得分.
(3) 你认为哪种计算平均得分的方法更合理？为什么？
6. 某县三个镇的人数及人均耕地面积如下表所示.

镇	人数/万人	人均耕地面积/hm ²
A	15	0.15
B	7	0.21
C	10	0.18

求这三个镇的人均耕地面积（结果保留小数点后两位）.

7. 某学校各年级的人数及某天早操的出勤率如下表所示.

年级	人数	出勤率/%
七年级	400	98
八年级	350	96
九年级	380	95

求这所学校早操的出勤率（结果写成 $a\%$ 的形式，其中 a 取整数）.

8. 某商场招聘一名员工, 现有甲、乙、丙三人竞聘. 通过计算机、语言和商品知识三项测试, 他们各自的成绩 (百分制) 如下表所示.

应试者	计算机	语言	商品知识
甲	70	50	80
乙	90	75	45
丙	50	60	85


- (1) 若商场需要招聘负责将商品拆装上架的人员, 对计算机、语言和商品知识分别赋权 2, 3, 5, 计算三名应试者的平均成绩. 从成绩看, 应该录取谁?
- (2) 若商场需要招聘电脑收银员, 计算机、语言、商品知识成绩分别占 50%, 30%, 20%, 计算三名应试者的平均成绩. 从成绩看, 应该录取谁?
9. 某地某个月中午 12 时的气温 (单位: $^{\circ}\text{C}$) 如下:

22 31 25 13 18 23 13 28 30 22 20 20 27 17 28
21 14 14 22 12 18 21 29 15 16 14 31 24 26 29

- (1) 求这个月中午 12 时的平均气温 (结果取整数);
- (2) 请以 4 为组距对数据分组, 作出频数分布表, 根据频数分布表计算这个月中午 12 时的平均气温, 与 (1) 中的结果比较, 你有什么发现, 谈一谈你的看法.
10. 下表是某养鸡场的一批鸡出售时质量的统计数据.

质量/kg	1.3	1.6	1.9	2.1	2.3
频数	53	108	348	275	216

- 分别求这批鸡质量的平均数 (结果保留小数点后一位)、中位数和众数.
11. 下图是一个路口某个时段来往车辆的车速情况.




(第 11 题)

应用你所学的统计知识，写一份简短的报告，向交警描述这个时段路口来往车辆的车速情况.

拓展探索

12. 学校举办为儿童福利院捐书的活动，三个班的捐书情况如图所示.



(第 12 题)

1 班捐书册数的平均数、中位数哪个大？2 班和 3 班呢？请你解释其中的原因.

13. 调查你所在小组同学最近一周体育锻炼的时间，应用所学的统计知识分析数据，并对自己所在小组的体育锻炼情况作出评价.

信息技术应用

利用统计软件求统计量

统计中经常会涉及数据的计算. 当数据量不大时，可以通过纸笔进行计算. 当数据量很大时，用纸笔计算不仅工作量大、效率低，而且容易出错. 为了从烦琐、机械的计算中解放出来，提高计算的效率和准确性，现在人们经常借助计算器或计算机等信息技术工具进行统计计算. 下面以借助某软件计算第 149 页“问题 1”中的平均数和第 152 页“例 2”中的加权平均数为例（不同软件或软件的不同版本，具体操作可能不同），介绍用信息技术工具求统计量的值.

一、平均数

1. 将问题 1 中甲组的数据输入表格（如 A2:A6）.
2. 点击一个空白单元格（如 A8），用于放置计算结果.
3. 在工具列中点击指令栏图标“ f_x ”，在调出的指令栏中输入指令“平均数(A2:A6)”或“mean(A2:A6)”，回车键确认即可计算得到甲组同学跳绳数据

的平均数，如图 1 所示。注意：指令表达式中括号和冒号要在半角状态下输入。

类似地，也可以得到乙组数据的平均数。


二、加权平均数

1. 将例 2 中的数据输入表格（如 A2:C3）。
2. 点击一个空白单元格（如 A5），用于放置计算结果。

3. 在工具列中点击指令栏图标 f_x ，在调出的指令栏中输入指令“平均数(A2:A3,C2:C3)”或“mean(A2:A3,C2:C3)”，回车键确认即可计算得到所有用户停留时间的加权平均数，如图 2 所示。


类似地，用指令“平均数(B2:B3,C2:C3)”或“mean(B2:B3,C2:C3)”，也可以得到所有用户对军事话题感兴趣的加权平均数。

在一些软件中，点击指令帮助图标 ，可以打开数学函数列表，进而查看用于求各种统计量值的指令及其调用格式。本章学习的所有统计量，都可以在其中找到相应的计算指令。



	A	B	C	D	E
1	甲	乙			
2	182	199			
3	194	148			
4	143	242			
5	185	170			
6	156	141			
7					
8	172				
9					
10					

图 1



	A	B	C
1	停留时间	百分数	用户数
2	0.5	0.24	30000000
3	0.7	0.32	10000000
4			
5	0.55		
6			
7			
8			
9			
10			

图 2

24.2 数据的离散程度

在数据分析中，除了集中趋势，数据的波动情况也是人们经常关注的特征，统计中把它称为数据的离散程度。本节我们将学习刻画一组数据离散程度的两个常见统计量——离差平方和、方差。

问题 某农业科学院专家为某地选择合适的甜玉米种子。选择种子时，甜玉米的产量和产量的稳定性是专家所关心的问题。为了解甲、乙两种甜玉米种子的相关情况，专家各用 10 块自然条件相同的试验田进行试验，得到各试验田每公顷的产量（单位：t）如表 24.2-1 所示。

表 24.2-1

甲	7.65	7.50	7.62	7.59	7.65	7.64	7.50	7.40	7.41	7.41
乙	7.55	7.56	7.53	7.44	7.49	7.52	7.58	7.46	7.53	7.49

根据这些数据估计，专家应该选择哪种甜玉米种子呢？

上面两组数据的平均数分别是

$$\bar{x}_{\text{甲}} = 7.537, \bar{x}_{\text{乙}} = 7.515.$$

说明在试验田中，甲、乙两种甜玉米的平均产量相差不多。由此可以估计出这个地区种植这两种甜玉米，它们的平均产量相差不多。

由样本平均数估计
总体平均数。

为了直观地观察甲、乙两种甜玉米在各试验田产量的分布情况，我们把表 24.2-1 中的两组数据分别用图形进行描述，如图 24.2-1 和图 24.2-2 所示。




图 24.2-1 甲种甜玉米的产量




图 24.2-2 乙种甜玉米的产量

比较两幅图可以看出,甲种甜玉米在各试验田的产量波动较大,多个产量离平均产量较远;而乙种甜玉米在各试验田的产量波动较小,较集中地分布在平均产量附近.因此,从直观上判断乙种甜玉米的产量稳定性更好.如何用一个值刻画一组数据的波动程度或离散程度呢?

正如图 24.2-1 和图 24.2-2 所呈现的,当数据分布比较分散时,数据与平均数的差异相对较大;当数据分布比较集中时,数据与平均数的差异相对较小.反过来也成立.这样,为了全面反映一组数据的离散程度,可以通过数据与平均数的差异来刻画.

一般地,有 n 个数据 $x_1, x_2, \dots, x_n$, 用 $\bar{x}$ 表示它们的平均数,我们把 $x_i - \bar{x}$ ($i=1, 2, \dots, n$) 叫作 x_i 关于平均数 $\bar{x}$ 的**离差** (deviation).

思考

可以用平均离差刻画一组数据的离散程度吗?

用离差可以刻画每个数据与平均数的差异,但由

$$(x_1 - \bar{x}) + (x_2 - \bar{x}) + \dots + (x_n - \bar{x}) = x_1 + x_2 + \dots + x_n - n\bar{x} = 0$$

可知,一组数据的离差和总是 0,因此平均离差无法刻画一组数据与平均数的差异.

为了避免离差求和时正负抵消的问题,统计中通常先对离差进行平方,然后求和.我们把

$$(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2$$

叫作这 n 个数据关于平均数的**离差平方和** (sum of squares of deviations),记作“ d^2 ”.把离差的平方的平均数

$$\frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n}$$

叫作这组数据的**方差** (variance),记作“ s^2 ”.方差反映了每个数据与平均数的平均差异程度,能较好地反映出数据的离散程度,是刻画数据离散程度最常用的统计量.方差越大,数据的离散程度越大;方差越小,数据的离散程度越小.

回到本节“问题”,根据表 24.2-1,可以得到

根据样本数据计算得到的方差,叫作样本方差;根据总体数据计算得到的方差,叫作总体方差.

$$s_{\text{甲}}^2 = \frac{(7.65-7.537)^2 + (7.50-7.537)^2 + \cdots + (7.41-7.537)^2}{10} \approx 0.010,$$

$$s_{\text{乙}}^2 = \frac{(7.55-7.515)^2 + (7.56-7.515)^2 + \cdots + (7.49-7.515)^2}{10} \approx 0.002.$$

由 $s_{\text{甲}}^2 > s_{\text{乙}}^2$ ，可得乙种甜玉米产量的离散程度较小，即乙种甜玉米产量波动较小，稳定性较好。

由此可知，在试验田中，乙种甜玉米的产量比较稳定。正如用样本的平均数估计总体的平均数一样，也可以用样本的方差来估计总体的方差。因此可以推测，在这个地区种植乙种甜玉米的产量比种植甲种的稳定。综合考虑甲、乙两个品种的平均产量和产量的稳定性，可以推测这个地区比较适合种植乙种甜玉米。

思考

用离差平方和是否可以刻画数据的离散程度？和方差比较，有什么不足？

离差平方和可以刻画一组数据的离散程度。在比较两组数据的离散程度时，离差平方和只适用于数据个数相同的情况，而方差则不受这个限制。

例 1 甲、乙两名气手枪运动员进行射击训练，10 次射击成绩（单位：环）如表 24.2-2 所示。

表 24.2-2

甲	9	7	9	10	10	8	9	10	5	10
乙	9	10	7	8	10	9	9	8	7	9

哪名射击运动员的发挥更稳定？

解：两名运动员射击成绩的平均数分别为

$$\bar{x}_{\text{甲}} = \frac{9+7+\cdots+10}{10} = 8.7,$$

$$\bar{x}_{\text{乙}} = \frac{9+10+\cdots+9}{10} = 8.6.$$

两名运动员射击成绩的方差分别为

$$s_{\text{甲}}^2 = \frac{(9-8.7)^2 + (7-8.7)^2 + \cdots + (10-8.7)^2}{10} = 2.41,$$


$$s_{乙}^2 = \frac{(9-8.6)^2 + (10-8.6)^2 + \cdots + (9-8.6)^2}{10} = 1.04.$$

由 $s_{甲}^2 > s_{乙}^2$ 可知, 乙射击运动员的发挥更稳定.


利用计算器的统计功能可以求方差. 使用计算器的统计功能求方差, 操作时需要参阅计算器的使用说明书. 通常先按某一功能键, 使计算器进入统计状态; 然后依次输入数据 $x_1, x_2, \cdots, x_n$; 最后按求方差的功能键, 计算器便会求出方差 $s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \cdots + (x_n - \bar{x})^2}{n}$ 的值.

练习


1. 如图, 有 4 组数据, 将这 4 组数据按离散程度从小到大排序. 先通过直观判断排序, 再根据方差排序. 这两种排序的结果是否一致?




(1)



(2)



(3)



(4)

(第 1 题)

2. 根据方差比较第 149 页“问题 1”中两组跳绳成绩的离散程度.

例 2 自动灌装线灌装饮料时，由于各种不可控的因素，每瓶饮料的实际含量与标准含量会存在一些误差（实际含量－标准含量）。甲、乙两条灌装线同时灌装标准含量为 500 mL 的饮料，为了检验两条灌装线的灌装质量，从每条灌装线上各随机抽取 10 瓶饮料进行测量，结果（单位：mL）如表 24.2-3 所示。

表 24.2-3

甲	501	496	498	499	503	498	505	498	501	501
乙	496	493	504	495	500	506	504	505	498	499

（1）如果有一瓶饮料含量的误差的绝对值超过 10 mL，此条灌装线的灌装质量为不合格，那么两条灌装线的灌装质量是否合格？

（2）哪条灌装线的灌装质量更好？

分析：在饮料含量的误差的绝对值符合要求前提下，灌装饮料的实际含量与标准含量的差异越小，说明灌装线的质量越好。

解：（1）甲、乙灌装线饮料的实际含量与标准含量 500 mL 的误差如表 24.2-4 所示。

表 24.2-4

甲组误差/mL	1	－4	－2	－1	3	－2	5	－2	1	1
乙组误差/mL	－4	－7	4	－5	0	6	4	5	－2	－1

从表 24.2-4 中的数据可以看出，甲、乙灌装线灌装的误差绝对值最大分别为 5 mL、7 mL，两者都小于 10 mL，因此两条灌装线灌装的质量都是合格的。

（2）甲、乙灌装线饮料实际含量的平均数分别为

$$\bar{x}_{\text{甲}} = \frac{501 + 496 + \cdots + 501}{10} = 500,$$

$$\bar{x}_{\text{乙}} = \frac{496 + 493 + \cdots + 499}{10} = 500.$$

两条灌装线饮料实际含量的平均数都等于标准含量。

可以类比方差，计算甲、乙灌装线饮料的实际含量与标准含量的平均差异程度，分别为

$$\frac{(501 - 500)^2 + (496 - 500)^2 + \cdots + (501 - 500)^2}{10} = 6.6,$$

$$\frac{(496-500)^2 + (493-500)^2 + \cdots + (499-500)^2}{10} = 18.8.$$

可以发现，甲灌装线饮料实际含量与标准含量的平均差异更小。

根据样本估计总体，综合来看，甲灌装线的灌装质量更好。

例 3 甲、乙两地同一天的气温记录如表 24.2-5 所示。

表 24.2-5

时刻	0:00	2:00	4:00	6:00	8:00	10:00	12:00	14:00	16:00	18:00	20:00	22:00	24:00
甲/℃	11	9	10	12	16	21	23	24	21	18	16	14	13
乙/℃	13	11	12	14	15	17	19	21	20	18	17	16	15

两地的气温有什么差异？

解：为了直观地观察两地气温的特点，以时刻为横坐标，气温为纵坐标，把表 24.2-5 中的数据用折线图进行表示，得到图 24.2-3。




图 24.2-3

从图 24.2-3 可以看出，甲、乙两地气温在不同的时刻互有高低，但甲地的最高气温高于乙地，而最低气温低于乙地。为进一步了解两地气温的差异，可以从数据的集中趋势和离散程度两个方面分别进行比较。

两地气温的平均数分别为

$$\bar{x}_{\text{甲}} = \frac{11+9+\cdots+13}{13} = 16, \quad \bar{x}_{\text{乙}} = \frac{13+11+\cdots+15}{13} = 16.$$

将两地气温按从小到大排列，可得

甲地 9 10 11 12 13 14 16 16 18 21 21 23 24

乙地 11 12 13 14 15 15 16 17 17 18 19 20 21

可以发现两地气温的中位数都是 16，众数各有两个（甲地是 16 和 21，乙地是 15 和 17）且都出现两次，因为重复次数太少，所以不具有代表性。因此，从数据的集中趋势看，两地的气温差异不明显。

两地气温的方差分别为

$$s_{\text{甲}}^2 = \frac{(11-16)^2 + (9-16)^2 + \cdots + (13-16)^2}{13} = \frac{306}{13} \approx 23.5,$$

$$s_{\text{乙}}^2 = \frac{(13-16)^2 + (11-16)^2 + \cdots + (15-16)^2}{13} = \frac{112}{13} \approx 8.6.$$

由 $s_{\text{甲}}^2 > s_{\text{乙}}^2$ 可知, 乙地气温的波动程度比甲地的小, 气温更稳定.

练习

1. 甲、乙两名运动员进行罚球线上投篮测试. 每人投篮 10 组, 每组投篮 10 次, 两名运动员投篮 10 组命中的次数如下表所示.

甲	8	6	9	6	8	10	7	7	10	9
乙	7	8	9	8	9	8	8	10	6	7

哪名运动员的投篮更稳定?

2. 甲、乙两台机床同时生产一种零件. 在 10 天中, 两台机床每天出次品的数量 (单位: 件) 如下表所示.


甲	0	1	0	2	2	0	3	1	2	4
乙	2	3	1	1	0	2	1	1	0	1

- (1) 分别计算两组数据的平均数和方差;
(2) 哪台机床的性能比较好?

习题 24.2

复习巩固

1. 甲、乙、丙三组数据的折线图如图所示, 根据图形比较各组数据方差的大小.
2. 甲、乙两台包装机同时包装食盐, 分别从中随机抽出 10 袋, 测得它们的实际质量 (单位: g) 如下表所示.



(第1题)

甲	501	506	508	508	497	508	506	508	507	499
乙	505	507	505	498	505	506	505	505	506	506

- (1) 分别计算两组数据的平均数和方差；
- (2) 哪台包装机包装食盐的质量比较稳定？

综合运用

3. 为了考察甲、乙两种小麦的长势，分别从中随机抽取 10 株麦苗，测得苗高（单位：cm）如下表所示.

甲	12	13	14	15	10	16	13	11	15	11
乙	11	16	17	14	13	19	6	8	10	16

- (1) 分别计算两种小麦的平均苗高；
- (2) 哪种小麦的长势比较整齐？
4. 在体操比赛中，往往在所有裁判员给出的分数中，去掉一个最高分和一个最低分，然后计算余下分数的平均分. 6 名裁判员对某一运动员的打分数数据（动作完成分）如下：

9.4 8.9 8.8 8.9 8.6 8.7.

- (1) 如果不去掉最高分和最低分，分别求这组数据的平均数（结果保留小数点后一位）和方差（结果保留小数点后两位）；
- (2) 如果去掉一个最高分和一个最低分，分别求这组数据的平均数（结果保留小数点后一位）和方差（结果保留小数点后两位）；
- (3) 你能从方差的角度解释哪种计算平均分的方法更合理吗？

拓展探索

5. 先任意写一组数据（如 2, 3, 5, 6, 9），计算其离差平方和；然后往数据中任意添加一个数据（如 4 或 5），再计算其离差平方和. 添加数据前后这组数据的离差平方和有什么变化？当添加什么数时，离差平方和不会变大？

24.3 数据的四分位数

集中趋势和离散程度都是数据分布某一方面的特征. 为了获取数据更多的信息, 人们还关心数据整体的分布情况. 本节我们将学习用四分位数大致刻画一组数据的分布情况.

问题 某银行有 A 和 B 两个理财产品经营团队. 近三年, 这两个团队分别负责经营 12 项理财产品, 收益率 (单位: %) 如下:

A	4.77	3.98	6.44	4.89	2.15	3.85
	3.64	3.21	3.18	2.02	4.11	4.10
B	3.18	3.84	3.99	3.67	3.40	3.60
	4.10	4.21	4.15	4.44	3.87	3.91

如果你是一位购买理财产品的投资者, 会选择哪个团队的产品?

我们可以用产品收益率的平均数和方差来刻画这两个团队的经营水平. 通过计算, 可以得到 A 和 B 两个团队产品收益率的平均数和方差分别为

$$\bar{x}_A \approx 3.862, s_A^2 \approx 1.327;$$

$$\bar{x}_B \approx 3.863, s_B^2 \approx 0.117.$$

可以看出, 团队 B 的产品收益率的平均数稍大于团队 A, 但差别不大; 团队 A 的产品收益率的方差明显大于团队 B, 即团队 B 的产品收益率的稳定性要好于团队 A. 因此, 如果你是稳健型投资者, 那么应该选择团队 B 经营的理财产品; 如果你是激进型投资者, 那么应该选择团队 A 经营的理财产品.

思考

如果投资者还想进一步了解两个团队理财产品收益率的具体情况, 例如收益率大部分在什么范围, 哪些范围比较集中等信息, 那么产品收益率的平均数和方差能反映出这些信息吗?

平均数和方差虽然可以反映产品收益率的集中趋势和离散程度, 但无法反映出投资客户关心的这些信息. 因此, 我们需要能反映产品收益率更多分布信息的统计量.

一组数据按从小到大的顺序排列，中位数是从中间点把数据分成 2 等份，将数据分成 100 等份的每一分点处的值叫作这组数据的**百分位数**。相比中位数，百分位数可以较全面地反映出数据的分布信息。

由于每个团队的产品收益率的数据个数不多，我们可以用三个特殊的百分位数来刻画。如图 24.3-1 所示，把团队 A 的产品收益率按从小到大的顺序排列，容易得到这组数据的中位数为 3.915，这个值把所有数据分成 2 等份，所有数据中小于这个值的占 50%，称 3.915 为这组数据的**50%分位数**。在 3.915 左侧和右侧的数据中，还可以分别得到它们各自的中位数 3.195 和 4.44，所有数据中小于这两个值的分别占 25%和 75%，称 3.195 和 4.44 分别为这组数据的**25%分位数**和**75%分位数**。由于 3.195，3.915，4.44 这三个值把这组按由小到大顺序排列的数据分成四等份，所以称它们为这组数据的**四分位数** (quartile)，从小到大分别称为这组数据的**第一四分位数**、**第二四分位数** (中位数)、**第三四分位数**，分别记为 Q_1 ， Q_2 ， Q_3 。

第一四分位数又称下四分位数，第三四分位数又称上四分位数。




图 24.3-1

由团队 A 产品收益率的三个四分位数，可以大致看出其产品收益率的分布情况。其产品收益率小于 3.195% 的项目数占总数的 25%，产品收益率小于 3.915% 的项目数占总数的一半，产品收益率大于 4.44% 的项目数占总数的 25%。产品收益率在 3.195% 至 4.44% 之间的项目数占总数的 50%。

类似地，如图 24.3-2，可以得到团队 B 产品收益率的三个四分位数分别为 3.635，3.89，4.125。




图 24.3-2

由团队 B 产品收益率的三个四分位数可以知道，其产品收益率小于

3.635%的项目数占总数的 25%，产品收益率小于 3.89%的项目数占总数的一半，产品收益率大于 4.125%的项目数占总数的 25%。产品收益率在 3.635%至 4.125%之间的项目数占总数的 50%。

为了更加直观地观察产品收益率的分布特征，我们可以用产品收益率的三个四分位数及最小值、最大值这五个数值画出箱线图 (box plot)。团队 A 产品收益率的箱线图如图 24.3-3 所示，它主要由矩形箱体和从箱体延伸出的两条水平线段（称为须线）构成。箱线图最左侧和最右侧的竖直线段分别表示这组数据的最小值和最大值，中间箱体的左端竖线表示第一四分位数，箱体中部的竖线表示第二四分位数（中位数），箱体的右端竖线表示第三四分位数，整个箱体的长度为第三四分位数减去第一四分位数的差，称为四分位距。由箱线图，容易看出产品收益率分布的大致情况，如分布的范围、中位数的大小、集中的范围、分布是否对称等。

从图 24.3-3 中你还能看出哪些分布信息？




图 24.3-3

类似地，可以画出团队 B 产品收益率的箱线图，如图 24.3-4 所示。




图 24.3-4

箱线图也可以按竖直方向画。为了便于比较两个团队产品收益率的分布特征，把两个箱线图按竖直方向并列画在同一幅图中，如图 24.3-5 所示。

从图 24.3-5 中可以发现，两个团队产品收益率的中位数几乎相等（表示中位数的水平线段差不多高），但团队 A 的产




图 24.3-5

品收益率波动明显比团队 B 的大（团队 A 的箱体和须线比团队 B 的长），这与用平均数、方差比较的结果是一致的。从箱线图中，还可以看出分布的一些其他特征，例如，团队 B 的产品收益率分布比团队 A 的更对称（中位数对应的水平线段在箱子的中间位置），团队 A 有约 25% 的产品收益率高于团队 B 的最高产品收益率，也有约 25% 的产品收益率低于团队 B 的最低产品收益率，等等。

与直方图、条形图比较，箱线图在表示数据方面有什么特点？

归纳

按从小到大的顺序排列的一组数据，可以按以下步骤确定其四分位数：先找出这组数据的中位数，作为这组数据的第二四分位数；然后找出中位数左侧和右侧的数据各自的中位数，分别作为这组数据的第一四分位数和第三四分位数。利用一组数据的三个四分位数，以及最小值、最大值可以刻画这组数据的大致分布情况。

例 根据第 173 页表 24.2-5 中的数据，分别计算甲、乙两地气温的四分位数，在同一幅图中画出箱线图，据此比较甲、乙两地的气温特点。

解：将表中两地的气温（单位：℃）分别按从小到大的顺序排列，可得

甲地 9 10 11 12 13 14 16 16 18 21 21 23 24

乙地 11 12 13 14 15 15 16 17 17 18 19 20 21

甲、乙两地气温各有 13 个数据。甲地气温的最小值为 9，最大值为 24，三个四分位数分别为

$$Q_2 = 16, Q_1 = \frac{11+12}{2} = 11.5, Q_3 = \frac{21+21}{2} = 21.$$

乙地气温的最小值为 11，最大值为 21，三个四分位数分别为

$$Q_2 = 16, Q_1 = \frac{13+14}{2} = 13.5, Q_3 = \frac{18+19}{2} = 18.5.$$

在同一幅图中画出两地气温的箱线图，如图 24.3-6 所示。

可以看出，甲、乙两地气温的中位数相同，但甲地气温的波动明显比乙地的大，甲地约有 25% 时刻的气温高于乙地的最高温度，约有 25% 时刻的气温低于乙地的最低温度。





图 24.3-6

练习

1. 某城市 9 月份空气质量指数的箱线图如图所示.




(第 1 题)

- (1) 这个月空气质量指数的最大值、最小值及四分位数分别是多少?
 - (2) 请分析这个月空气质量的特点.
2. 计算第 149 页“问题 1”中每组数据的四分位数, 在同一幅图中画出箱线图, 据此比较两个小组的跳绳成绩特点.
3. 任何一组数据的四分位数, 是否都恰好能把这组数据分成四等份? 举例说明.

习题 24.3

复习巩固

1. 以下是三组数据的直方图和箱线图的示意图, 把表示同一组数据的两个图形进行连线, 并说明理由.



(A)



(B)



(C)



(1)



(2)



(3)

(第 1 题)

2. 一家汽车零售店的 9 名销售人员 10 月份销售的汽车数量 (单位: 辆) 如下:

12 10 3 9 10 12 2 6 14

- (1) 计算汽车销售数量的四分位数;
- (2) 画箱线图并分析汽车销售数量的特点.

综合运用

3. 某班有 40 名同学，一次测试的成绩（百分制）如下：

32 44 54 55 58 62 65 65 68 69 69 69 70 71
71 72 73 74 75 75 75 76 77 77 78 79 80 80
81 83 85 85 87 87 89 90 92 94 99 99

请结合测试成绩的四分位数和箱线图分析这个班这次测试成绩的特点.

4. 八年级两个班男生的身高（单位：cm）分别如下：

甲班 164 171 163 158 167 175 169 181 168 176 175 162
166 165 172 169 171 168 174 170
乙班 172 170 163 161 179 160 176 174 170 178 183 166
168 167 180 171 168 172

请结合男生身高的四分位数和箱线图比较这两个班级男生的身高差异.

24.4 数据的分组

在社会生活中，分类现象普遍存在。例如，超市里各种商品按用途不同分类摆放，宾馆根据硬件设施、服务水平等分成不同的星级，等等。在实际问题中，当面临的对象复杂多样时，分类往往可以为我们处理问题带来方便。对于一组取值多样的数据，对其进行合理分组，也会有助于我们解决问题。

问题 一家公司向社会招聘一名员工，所有应聘者先统一参加笔试，然后根据笔试成绩确定一部分应聘者进入面试。将 10 名应聘者的笔试成绩（百分制）按从小到大的顺序排列如下：

58 64 68 75 76 83 85 89 90 92

你认为哪一部分应聘者应当进入面试？

自然，应当选择笔试成绩好的应聘者进入面试。那么笔试成绩怎样才算好呢？可以有不同的标准。例如，前三名或 85 分及以上等。不管哪种标准，目的都是把笔试成绩分成好和差两组。

对笔试成绩进行分组，上面提到的标准各有其合理性，在实际中也经常被采用。但这些标准都没有考虑数据自身的特点，这可能导致两个很接近的笔试成绩被分到不同的组。例如，83 分与 85 分的差距很小，若以“85 分及以上”为好成绩的标准，则 85 分属于好成绩，而 83 分属于差成绩。而从公司确定面试应聘者的角度看，把笔试成绩相对接近的分到同一组，是一种较合理的做法。因此，笔试成绩可以根据组内差异最小的原则进行分组。

将笔试成绩按从小到大的顺序排列，使相互最接近的笔试成绩都挨在了一起。因此，要使分组后的组内差异最小，只需在已排序数据的基础上寻找分组方法。可以发现，10 个笔试成绩按顺序排列形成 9 个间隔，如图 24.4-1 所示。

58 | 64 | 68 | 75 | 76 | 83 | 85 | 89 | 90 | 92

图 24.4-1

每个间隔都可以把笔试成绩分成好和差两组，共有 9 种分法。

思考

怎么刻画组内笔试成绩差异的大小呢？哪种分法能使笔试成绩好和差两组的组内差异最小？

在前面的学习中，我们知道，离差平方和可以刻画一组数据的离散程度。下面我们利用离差平方和刻画组内数据的离散程度，进而对数据进行分组。

一般地，设有 n 个数据 $x_1, x_2, \dots, x_n$ ，其平均数记为 $\bar{x}$ ，则离差平方和为

$$d^2 = (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2.$$

如果把这组数据分为两组，前 m ($m < n$) 个数据为一组，后 $(n-m)$ 个数据为一组，它们的平均数分别记为 $\bar{x}_1$ 和 $\bar{x}_2$ ，离差平方和分别为

$$d_1^2 = (x_1 - \bar{x}_1)^2 + (x_2 - \bar{x}_1)^2 + \dots + (x_m - \bar{x}_1)^2,$$

$$d_2^2 = (x_{m+1} - \bar{x}_2)^2 + (x_{m+2} - \bar{x}_2)^2 + \dots + (x_n - \bar{x}_2)^2,$$

那么

$$\begin{aligned} d^2 &= (x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2 \\ &= (x_1 - \bar{x}_1 + \bar{x}_1 - \bar{x})^2 + (x_2 - \bar{x}_1 + \bar{x}_1 - \bar{x})^2 + \dots + (x_m - \bar{x}_1 + \bar{x}_1 - \bar{x})^2 + \\ &\quad (x_{m+1} - \bar{x}_2 + \bar{x}_2 - \bar{x})^2 + (x_{m+2} - \bar{x}_2 + \bar{x}_2 - \bar{x})^2 + \dots + (x_n - \bar{x}_2 + \bar{x}_2 - \bar{x})^2 \\ &= (x_1 - \bar{x}_1)^2 + (x_2 - \bar{x}_1)^2 + \dots + (x_m - \bar{x}_1)^2 + (x_{m+1} - \bar{x}_2)^2 + \\ &\quad (x_{m+2} - \bar{x}_2)^2 + \dots + (x_n - \bar{x}_2)^2 + m(\bar{x}_1 - \bar{x})^2 + (n-m)(\bar{x}_2 - \bar{x})^2 \\ &= d_1^2 + d_2^2 + m(\bar{x}_1 - \bar{x})^2 + (n-m)(\bar{x}_2 - \bar{x})^2. \end{aligned}$$

其中 $d_1^2 + d_2^2$ 称为组内离差平方和，表示两个组内数据的离散程度；记

$$d_{12}^2 = m(\bar{x}_1 - \bar{x})^2 + (n-m)(\bar{x}_2 - \bar{x})^2,$$

d_{12}^2 是 m 个第一组数据平均数、 $(n-m)$ 个第二组数据平均数关于总体数据平均数的离差平方和，称为组间离差平方和，表示两个组间的差异。根据组内离差平方和最小的原则进行分组时，由于 d^2 不变，既可以按 $d_1^2 + d_2^2$ 最小来分组，也可以按 d_{12}^2 最大来分组。

这样，根据组内离差平方和最小的原则，能使笔试成绩相差较小的应聘者分在同一组。利用计算器或信息技术工具，可以计算出图 24.4-1 中的 9 种分法的组内离差平方和（结果保留小数点后一位），如表 24.4-1 所示。

表 24. 4-1

分组	第一组离差平方和	第二组离差平方和	组内离差平方和
第 1 个间隔	0	799. 6	799. 6
第 2 个间隔	18	503. 5	521. 5
第 3 个间隔	50. 7	271. 4	322. 1
第 4 个间隔	152. 8	170. 8	323. 6
第 5 个间隔	228. 8	54. 8	283. 6
第 6 个间隔	411. 3	26	437. 3
第 7 个间隔	587. 4	4. 7	592. 1
第 8 个间隔	819. 5	2	821. 5
第 9 个间隔	1 026. 2	0	1 026. 2

观察最后一列组内离差平方和可以发现，当按第 5 个间隔分组时，组内离差平方和最小．因此，按组内离差平方和最小的分法为

$$\{58, 64, 68, 75, 76\}$$

和

$$\{83, 85, 89, 90, 92\}.$$

例 10 个城市某月的每日最高温度的平均数（简称平均高温）如表 24. 4-2 所示.

表 24. 4-2

城市	北京	石家庄	呼和 浩特	哈尔滨	上海	广州	海口	成都	贵阳	昆明
平均高 温/℃	3	3	—3	—11	10	21	22	12	9	17

根据平均高温的组内离差平方和最小的原则，把这 10 个城市分为两组.

解：将表中的数据按从小到大排列，可得

$$-11 \quad -3 \quad 3 \quad 3 \quad 9 \quad 10 \quad 12 \quad 17 \quad 21 \quad 22$$

将它们分成两组共有 9 种情况，利用计算器或信息技术工具，分别计算组内离差平方和（结果保留小数点后一位），如表 24. 4-3 所示.